



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
UNIVERSITY OF PIRAEUS

Ανίχνευση Συναισθημάτων σε Ηχητικά Δεδομένα

Μηχανική Μάθηση 2025 - 2026

Γκούβρα Ελπίδα, Πλέσσας Γιώργος, Τσαγκέτας Ορέστης

Εισαγωγή

Αντικείμενο

Ανίχνευση συναισθημάτων σε πραγματικά ηχητικά σήματα, εστιάζοντας στην εξαγωγή χαρακτηριστικών από την ομιλία.

Πρόκληση

Δημιουργία συστήματος που κατανοεί τις διαφορές μεταξύ των ανθρώπων στην έκφραση των συναισθημάτων.

Στόχος

Ταξινόμηση 4 κλάσεων (Angry, Happy, Neutral, Sad) με κλασικά μοντέλα ML.

Δεδομένα & Μεθοδολογία

Δεδομένα

IEMOCAP Dataset

Interactive Emotional Dyadic Motion Capture

5 Sessions 5,531 Samples

Το κύριο dataset εκπαίδευσης. Ηχητικά δεδομένα από διαλόγους ηθοποιών.

Angry Happy+Exc Neutral Sad

CREMA-D Dataset

Crowd-sourced Emotional Multimodal Actors

91 Actors 4,900 Samples

Χρήση αποκλειστικά για Zero-Shot Evaluation.

Μεθοδολογία

- Προεπεξεργασία Ήχου**
Resampling στα 16kHz, Normalization (max abs value), αφαίρεση σιωπής (Trim silence top_db=20) και Framing.
- Εξαγωγή Χαρακτηριστικών**
Χρήση `pyAudioAnalysis`. Παράθυρο 50ms / Βήμα 25ms.
272 Features: Time-domain, Spectral (MFCCs, Chroma), Deltas
- Μοντέλα Μηχανικής Μάθησης**
Εκπαίδευση 7 κλασικών ταξινομητών:

XGBoost	SVM	Random Forest
Logistic Reg	KNN	Naive Bayes
Decision Tree		

Σενάρια Εργασίας



1. Σενάριο 1: IEMOCAP 80/20 split

Preprocess



Split 80/20



StandardScaler



Train/Tune



2. Σενάριο 2: IEMOCAP LOSO

Preprocess



Split



5-Fold Session Split



Fold Training



Train/Tune



3. Σενάριο 3: IEMOCAP 80/20 + PCA

Preprocess



Split



PCA



Train/Tune



Zero-Shot Evaluation

CREMA-D Dataset

Όλα τα μοντέλα από κάθε workflow δοκιμάζονται αυτόματα στο CREMA-D χωρίς καμία επανεκπαίδευση.

Αρχιτεκτονική

Steps για κατασκευή των pipelines

- **Προεπεξεργασία:** Καθαρισμός, κανονικοποίηση και προετοιμασία χαρακτηριστικών.
- **Στρατηγικές Split:** Διαφορετικά splits (Hold-out, Cross-validation, LOSO).
- **Εκπαίδευση:** Πολλαπλά μοντέλα (SVM, RF, XGB, κ.α.).
- **Βελτιστοποίηση:** Fine-tuning υπερπαραμέτρων για καλύτερη απόδοση.
- **Αξιολόγηση:** Μετρικές, πίνακες σύγχυσης και learning curves.
- **Ανάλυση PCA:** Μείωση διαστάσεων για πιο ελαφρύ μοντέλο.
- **Συγκριτική Αξιολόγηση:** Τελική σύγκριση όλων των pipelines με AUC.

Pipelines: Σενάρια

Pipeline

- Κάθε pipeline συνθέτει τα βήματα σε ένα πλήρες, αυτοματοποιημένο σενάριο.
- Ενιαία ροή από preprocessing μέχρι αξιολόγηση, χωρίς χειροκίνητα κενά.

Απομόνωση

- Κάθε πείραμα έχει τη δική του δομή (features → models → results) για καθαρό διαχωρισμό.
- Εύκολη διαχείριση και καθάρισμα ανά σενάριο.

Επισκόπηση Σεναρίων

1. Σενάριο 1

80/20 STRATIFIED

Baseline αξιολόγηση

- Step 1: Preprocess IEMOCAP.
- Step 2: Stratified 80/20 split + normalize.
- Step 3: Train models.
- Step 4: Evaluate models.
- Step 5: Hyperparameter tuning.
- Step 6: Evaluate tuned models.
- Step 7: Zero-Shot Evaluation (CREMA-D).

2. Σενάριο 2

LOSO STRATEGY

Γενίκευση Προβλέψεων

- Step 1: Preprocess IEMOCAP.
- Step 2: LOSO split (folds).
- Step 3: Train/tune per fold.
- Step 4: Evaluate per fold.
- Step 5: Zero-Shot Evaluation per fold.
- Step 6: Aggregate LOSO results.

3. Σενάριο 3

PCA OPTIMIZATION

Μείωση Διαστάσεων

- Step 1: Preprocess IEMOCAP.
- Step 2: 80/20 split (raw, no normalize).
- Step 3: PCA στο train (~99.03% variance).
- Step 4: Train models (no-scale).
- Step 5: Evaluate models.
- Step 6: Hyperparameter tuning.
- Step 7: Evaluate tuned models.
- Step 8: Zero-Shot Evaluation (CREMA-D).

Σενάριο 1

1

Προεπεξεργασία Δεδομένων

Εξαγωγή χαρακτηριστικών από τα ηχητικά αρχεία IEMOCAP με pyAudioAnalysis.

2

Διαχωρισμός Train/Test

Stratified split 80/20 (Train: 4.424, Test: 1.107) με κανονικοποίηση.

3

Εκπαίδευση Μοντέλων

Εκπαίδευση 7 ταξινομητών (XGBoost, SVM, RF, Logistic Reg, KNN, NB, DTR).

4

Αρχική Αξιολόγηση

Αξιολόγηση με confusion matrices, learning curves και metrics.



Βασικές Πληροφορίες

Dataset

IEMOCAP (5.531 samples)

Train/Test Split

80% / 20%
(stratified)

Train Samples

4.424

Test Samples

1.107

Features

272 (68 × 4 stats)

Models

XGBoost

SVM

RF

Logistic Reg

KNN

NB

DTR

Σενάριο 1

5

Hyperparameter Tuning

RandomizedSearchCV με weighted F1-score.

6

Τελική Αξιολόγηση

Αξιολόγηση των βελτιστοποιημένων μοντέλων με τα ίδια metrics για σύγκριση.

7

Zero-Shot Evaluation

Έλεγχος γενίκευσης σε CREMA-D dataset. Τα μοντέλα αξιολογούνται χωρίς επανεκπαίδευση.

Zero-Shot Ranking (CREMA-D) - Accuracy

1

Naive Bayes

54.29%

2

XGBoost

52.22%

3

SVM

50.82%

4

KNN

48.82%

5

Random Forest

47.04%

6

Logistic Reg

44.37%

7

Decision Tree

35.24%

Σενάριο 2

1

Preprocessing & Feature Extraction

Καθαρισμός δεδομένων IEMOCAP και εξαγωγή χαρακτηριστικών.

2

Iterative Splitting

Επανάληψη διαδικασίας για κάθε ομιλητή. Test: 1 Speaker | Train: Remaining Speakers.

3

Normalization & Training

Εφαρμογή Scaler μόνο στο Train set. Εκπαίδευση μοντέλων όπως SVM, RF, XGB ή βελτιστοποίηση υπερπαραμέτρων.

4

Evaluation

Αξιολόγηση στο Test set του τρέχοντος fold. Καταγραφή μετρικών απόδοσης.

Χαρακτηριστικά & Στόχοι

Speaker Independence

Διασφαλίζει ότι το μοντέλο μαθαίνει συναισθηματικά χαρακτηριστικά και όχι την ταυτότητα του ομιλητή. Αποφεύγει το overfitting σε συγκεκριμένες φωνές.

Ανθεκτικότητα

Προσομοιώνει ρεαλιστικές συνθήκες όπου το σύστημα καλείται να αναγνωρίσει το συναίσθημα ενός νέου, άγνωστου χρήστη.

Data Efficiency

Χρησιμοποιεί το μεγαλύτερο μέρος των δεδομένων για εκπαίδευση σε κάθε fold (~80-90%), διατηρώντας παράλληλα αυστηρό διαχωρισμό για την αξιολόγηση.

Σενάριο 2

4

Evaluation

Αξιολόγηση στο Test set του τρέχοντος fold. Καταγραφή μετρικών απόδοσης.

5

Zero-Shot Evaluation

Πρόβλεψη σε εξωτερικό dataset CREMA-D για έλεγχο γενίκευσης σε εντελώς άγνωστα δεδομένα.

6

Aggregation

Συγκέντρωση αποτελεσμάτων από όλα τα folds. Υπολογισμός μέσου όρου και τυπικής απόκλισης.

Zero-Shot Ranking (CREMA-D) - Accuracy

1

Naive Bayes

53.71%

2

SVM

51.84%

3

XGBoost

51.13%

4

Random Forest

47.17%

5

KNN

47.09%

6

Logistic Reg

38.66%

7

Decision Tree

36.87%

Σενάριο 2

Zero-Shot ανά fold

MODEL	FOLD 0	FOLD 1	FOLD 2	FOLD 3	FOLD 4	AVG
Naive Bayes	53.10%	53.94%	54.08%	54.00%	53.43%	53.71%
SVM	54.27%	51.80%	49.27%	50.94%	52.96%	51.84%
XGBoost	52.04%	50.33%	52.00%	50.57%	50.73%	51.13%
Random Forest	50.76%	44.49%	44.47%	46.65%	49.49%	47.17%
KNN	46.41%	46.49%	48.88%	46.31%	47.37%	47.09%
Logistic Reg	36.67%	38.94%	36.02%	39.94%	41.71%	38.66%
Decision Tree	38.20%	39.06%	37.45%	35.73%	33.92%	36.87%

Σενάριο 3

1

Προεπεξεργασία

Καθαρισμός δεδομένων και εξαγωγή χαρακτηριστικών.

2

Διαχωρισμός Train/Test

Διαχωρισμός 80/20 χωρίς κανονικοποίηση.

3

PCA

Εφαρμογή PCA στο train (variance 0,99)

4

Εκπαίδευση

Εκπαίδευση μοντέλων.

Κύρια Σημεία

PCA

272 διαστάσεις → 205 components (99.03% variance).

Linear

Logistic Reg 59.08% · SVM 61.16%

Trees

RF/XGB ασθενούν με PCA.

KNN/NB/DTR

Χαμηλή απόδοση στο PCA setup.

Σενάριο 3

5

Αξιολόγηση

Αξιολόγηση μοντέλων.

6

Tuning

RandomizedSearchCV και επαναξιολόγηση.

7

Zero-Shot Evaluation

Zero-Shot Evaluation στο CREMA-D με ίδιο PCA/scaler.



Zero-Shot Ranking (CREMA-D) - Accuracy

1

SVM

51.16%

2

KNN

49.06%

3

XGBoost

47.04%

4

Random Forest

45.22%

5

Logistic Reg

44.53%

6

Decision Tree

41.84%

7

Naive Bayes


30.76%

Αποτελέσματα: Σενάριο 1


Σύγκριση Test (IEMOCAP) vs Zero-Shot (CREMA-D)

MODEL	ACC		F1-W		F1-M		UAR		PREC-W		REC-W	
	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO
XGBoost	62.24%	52.22%	62.21%	52.48%	62.59%	52.26%	62.25%	52.50%	62.80%	55.20%	62.24%	52.22%
SVM	61.25%	50.82%	61.25%	50.12%	61.83%	50.08%	61.58%	51.39%	61.55%	56.00%	61.25%	50.82%
Logistic Reg	59.89%	44.37%	59.83%	44.39%	60.39%	44.14%	60.50%	44.14%	59.86%	50.92%	59.89%	44.37%
Random Forest	58.81%	47.04%	58.78%	44.45%	59.17%	44.62%	58.60%	48.71%	59.49%	61.79%	58.81%	47.04%
KNN	55.65%	48.82%	55.19%	47.60%	55.80%	47.36%	56.52%	48.92%	55.88%	49.01%	55.65%	48.82%
Naive Bayes	49.23%	54.29%	47.80%	51.35%	49.45%	51.21%	52.86%	54.38%	49.47%	53.12%	49.23%	54.29%
Decision Tree	46.88%	35.24%	46.80%	36.39%	47.25%	36.16%	47.09%	35.20%	46.94%	46.74%	46.88%	35.24%


Zero-shot Results Heatmap – Σενάριο 1



Zero-shot Results Heatmap – Σενάριο 2



Zero-shot Results Heatmap – Σενάριο 3



Αποτελέσματα: Σενάριο 2

Σύγκριση Test vs Zero-Shot

MODEL	ACC		F1-W		F1-M		UAR		PREC-W		REC-W	
	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO
SVM	56.38%	51.84%	56.34%	50.29%	57.04%	50.29%	57.13%	52.72%	58.01%	57.48%	56.38%	51.84%
XGBoost	56.26%	51.13%	56.13%	50.70%	56.63%	50.49%	57.13%	51.31%	57.22%	53.28%	56.26%	51.13%
Random Forest	54.55%	47.17%	54.47%	44.45%	54.99%	44.64%	55.01%	48.78%	56.53%	60.41%	54.55%	47.17%
Logistic Reg	53.58%	38.66%	53.20%	36.68%	53.65%	36.32%	54.62%	38.02%	54.20%	45.48%	53.58%	38.66%
KNN	51.53%	47.09%	51.05%	46.06%	51.37%	45.75%	52.26%	47.10%	52.98%	48.28%	51.53%	47.09%
Naive Bayes	47.95%	53.71%	46.37%	50.50%	47.52%	50.34%	51.22%	53.74%	48.10%	52.22%	47.95%	53.71%
Decision Tree	43.67%	36.87%	43.67%	36.69%	43.65%	36.62%	43.95%	37.25%	44.57%	41.30%	43.67%	36.87%

Παρατηρήσεις

Με βάση το **Accuracy**, το καλύτερο Test μοντέλο είναι SVM (56.38%). Στο Zero-Shot (CREMA-D) ξεχωρίζει το Naive Bayes (53.71%), δείχνοντας καλύτερη γενίκευση.

Αποτελέσματα: Σενάριο 3

Σύγκριση Test vs Zero-Shot

MODEL	ACC		F1-W		F1-M		UAR		PREC-W		REC-W	
	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO	TEST	ZERO
SVM	61.16%	51.16%	61.15%	50.55%	61.66%	50.49%	61.42%	51.71%	61.42%	56.12%	61.16%	51.16%
Logistic Reg	59.08%	44.53%	59.00%	44.54%	59.61%	44.28%	59.79%	44.33%	59.05%	51.21%	59.08%	44.53%
XGBoost	56.19%	47.04%	56.18%	47.37%	56.67%	47.16%	56.36%	47.19%	56.41%	49.91%	56.19%	47.04%
KNN	55.83%	49.06%	55.41%	47.96%	56.07%	47.69%	56.72%	49.12%	56.03%	49.28%	55.83%	49.06%
Random Forest	55.19%	45.22%	54.69%	44.74%	54.25%	44.83%	53.01%	46.30%	58.30%	55.82%	55.19%	45.22%
Decision Tree	47.34%	41.84%	46.94%	42.19%	46.89%	42.12%	46.47%	42.49%	47.61%	47.35%	47.34%	41.84%
Naive Bayes	39.30%	30.76%	38.14%	22.91%	38.87%	22.69%	42.54%	30.01%	44.65%	25.06%	39.30%	30.76%

Παρατηρήσεις


Με βάση το **Accuracy**, το καλύτερο Test μοντέλο είναι SVM (61.16%). Στο Zero-Shot (CREMA-D) ξεχωρίζει το SVM (51.16%), δείχνοντας καλύτερη γενίκευση.

Καμπύλες ROC ανά σενάριο

Macro AUC (one-vs-rest) ανά σενάριο


Σενάριο 1: 80/20 Split (IEMOCAP)

Ένα train/test split · καλύτερο: XGBoost (AUC 0.8542)




Σενάριο 2: Leave-One-Speaker-Out (LOSO)

Μέσος AUC ανά fold · καλύτερο: Random Forest (AUC 0.7572)



Σενάριο 3: 80/20 + PCA

Μειωμένη διασπορά · καλύτερο: SVM (AUC 0.8466)



Συμπεράσματα


Σύνοψη αποτελεσμάτων σεναρίων

Σύγκριση Ακρίβειας (Accuracy)

Σενάριο 1: IEMOCAP 80/20 (Baseline) Best Case



Σενάριο 2: IEMOCAP LOSO (Speaker-Independent) ~6% Drop



Σενάριο 3: Η Επίδραση του PCA

Η μείωση διαστάσεων (272 → 205, 99.03% variance) επηρέασε διαφορετικά τις οικογένειες μοντέλων:

LINEAR MODELS

↑ **Stable**

LogReg & SVM διατηρούν ~60%

TREE MODELS

↓ **4-6%**

XGBoost & RF μειώνονται



Zero-Shot Surprise (CREMA-D)

Έλεγχος γενίκευσης

54.29%

Naive Bayes

Παράδοξο: Το Naive Bayes έχει σχετικά χαμηλή απόδοση στο IEMOCAP (49.23%), αλλά την καλύτερη γενίκευση στο CREMA-D.

🔍 Ένδειξη *overfitting* των πολύπλοκων μοντέλων (XGB/SVM) στα ιδιαίτερα χαρακτηριστικά του IEMOCAP.