

Fictitious play and reinforcement learning for computing equilibria

Πλέσσιας Γιώργος, Τσαγκέτας Ορέστης

Intelligent Agents & Multiagent Systems — Φεβρουάριος 2026

Στόχοι & Κίνητρο

Αντικείμενο

Μελέτη συμπεριφοράς πρακτόρων σε ανταγωνιστικά περιβάλλοντα: σύγκριση **Fictitious Play** και **Q-Learning** σε zero-sum games και στοχαστικά turn-based παίγνια.

Πρόκληση

Η «σύγκλιση στο Nash» δεν ταυτίζεται με «καλύτερο reward» — ιδίως όταν ο αντίπαλος δεν είναι στάσιμος ή και οι δύο μαθαίνουν ταυτόχρονα.

Στόχος

Κατανόηση δυνατοτήτων/αδυναμιών κάθε αλγορίθμου μέσω πειραμάτων σε: **Matching Pennies**, **Rock-Paper-Scissors** και **Grid Hunter-Prey**.

Μεθοδολογία

Σενάρια: FP vs FP, FP vs RL, RL vs RL, MinMax vs RL.

Παίγνια

Matching Pennies

2×2 matrix

NE: (0.5, 0.5)

Rock-Paper-Scissors

3×3 matrix

NE: ($\frac{1}{3}$, $\frac{1}{3}$, $\frac{1}{3}$)

Grid Hunter-Prey

3×3 turn-based

Capture ± 10

Παράμετροι Πειραμάτων

Παράμετρος	Matrix	Grid
Iterations / Turns	10.000	200.000
Learning rate (α)	0.1	0.1 + decay
Epsilon (ϵ)	0.1	0.1 + decay
Discount (γ)	—	0.99
Minimax depth	—	4
Seed	42	42

Θεωρητικό Πλαίσιο

Zero-Sum Παίγνια

Δύο παίκτες, $U_1 + U_2 = 0$. Πίνακας αποδόσεων $M \in \mathbb{R}^{m \times n}$.

Μικτές στρατηγικές: $x \in \Delta_m, y \in \Delta_n$.

$$u(x, y) = x^T M y$$

Ισορροπία Nash

Ζεύγος (x^*, y^*) — κανένας δεν βελτιώνεται μονομερώς:

$$x^* \in \operatorname{argmax}_x x^T M y^* \mid y^* \in \operatorname{argmin}_y (x^*)^T M y$$

Στα MP & RPS δεν υπάρχει Pure NE, μόνο μοναδικό Mixed NE.

Θεώρημα Minimax

$$\max_x \min_y x^T M y = \min_y \max_x x^T M y$$

Η minimax στρατηγική ταυτίζεται με το Nash σε zero-sum.

Fictitious Play model-based

Belief = εμπειρική συχνότητα αντιπάλου:

$$\hat{y}_t(a) = w_t(a) / \sum_{a'} w_t(a')$$

Επιλογή: Best Response στο belief (ντετερμινιστική).

Robinson: Συγκλίνει στο mixed Nash σε zero-sum self-play. Ευάλωτη σε adaptive αντιπάλους.

Q-Learning model-free

$$Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a')]$$

ϵ -greedy: random (prob ϵ) | $\operatorname{argmax} Q$ (prob $1 - \epsilon$).

Σε δυναμικό περιβάλλον δεν εγγυάται σύγκλιση σε Nash.

Matching Pennies — FP vs FP

0.0007

FP1 Nash Distance

0.0092

FP2 Nash Distance

+60 / -60


Cumulative Reward

± 0.006


Average Payoff



Εξέλιξη στρατηγικής P1




Απόσταση από Nash



Cumulative Reward

Θεώρημα Robinson: Οι εμπειρικές συχνότητες συγκλίνουν στο μεικτό Nash (0.5, 0.5). Αν και οι αμιγείς στρατηγικές διακυμαίνονται, τα μακροπρόθεσμα στατιστικά σταθεροποιούνται και κανένας παίκτης δεν αποκτά πλεονέκτημα.

Matching Pennies — FP vs RL



Μετρική	FP	RL
Distance Nash	0.0000	0.6642
Σωρευτική	-374	+374
External regret	388	-374

FP Distance: 0.0000 | RL: 0.6642 | Reward: -374 / +374


«Nash» ≠ Νίκη — προσφέρει προστασία απέναντι στον ορθολογικό παίκτη, αφήνοντας ανεκμετάλλευτα τα σφάλματα ενός εξελισσόμενου αντιπάλου.




Ανάλυση

- FP στο Nash (distance 0) αλλά **χάνει** (-374).
- RL μακριά από Nash (0.66) αλλά **κερδίζει** (+374).
- FP regret: **388** (γραμμικό) → δεν είναι no-regret.
- RL μαθαίνει τη ντετερμινιστική BR της FP.

Matching Pennies — RL vs RL & Exploitability




Απόσταση Nash



Cumulative Reward

Exploitability Heatmap




	$\epsilon=0.05$	$\epsilon=0.10$	$\epsilon=0.20$
$\alpha=0.01$	1.9099	1.8217	1.6508
$\alpha=0.10$	1.9099	1.8217	1.6508
$\alpha=0.50$	1.9099	1.8217	1.6508


Exploitability εξαρτάται **μόνο από ϵ** . Μεγαλύτερο $\epsilon \rightarrow$ πιο ομοιόμορφη στρατηγική $\rightarrow$ μικρότερη exploitability.

Rock-Paper-Scissors — Αποτελέσματα

Σενάριο	Distance P1/P2	Cumul. P1/P2	Regret FP/RL	Παρατηρήσεις
FP vs FP	0.0032 / 0.0032	0 / 0	—	Τέλεια σύγκλιση ($\frac{1}{3}, \frac{1}{3}, \frac{1}{3}$)
FP vs RL	0.0152 / 0.7670	-213 / +213	234 / -3	RL εκμεταλλεύεται FP
RL vs RL	0.7670 / 0.7670	+212 / -212	—	Κυκλική, ισχυρή ασυμμετρία



FP vs RL: Cumulative Reward




RL vs RL: Cumulative Reward

Grid Hunter-Prey — MinMax vs RL


Πλάνο 3x3, max_steps=20. Hunter=**Minimax** (depth 4), Prey=**Stochastic Q-Learning**.

Πρώτος	Episodes	Captures	Rate	Hunter Reward	Mean
Hunter	10.264	670	6.5%	+6.998,5	+0.070
Prey	10.282	682	6.6%	-87.868,8	-0.879



Hunter First

MinMax κυριαρχεί: θετικό reward (+6.998). RL Prey μαθαίνει σταδιακά να αποφεύγει ($\epsilon \rightarrow 0.068$).




Prey First


Capture rate παρόμοιο (6.6%) αλλά reward **-87.869**. Timeouts $\rightarrow$ -10 ανά timeout.

Capture rate ≠ απόδοση: Η κατανομή εκβάσεων (timeouts vs captures) αλλάζει δραματικά με τη σειρά κίνησης.

Grid Hunter-Prey — RL vs RL




Hunter first: Cumulative



Prey first: Cumulative



Hunter first: Average Reward




MinMax vs RL: Average Reward

Grid Hunter-Prey — Προσομοιώσεις

Οπτικοποίηση συμπεριφοράς των πρακτόρων σε διάφορα σενάρια

Best Run

Best Run: 5 Steps (Captured)
Step: 0




Hunter Prey

Καλύτερη απόδοση: 5 βήματα (Captured)

Prey Escape

Prey Escape: 20 Steps (Escaped)
Step: 0




Hunter Prey

Επιτυχής διαφυγή: 20 βήματα (Escaped)

Early Episode

Ep 1: Random (3x3)
Step: 0



Hunter Prey

Πρώτο επεισόδιο: Random (3x3)

Παρατηρήσεις: Τα GIFs δείχνουν την εξέλιξη της συμπεριφοράς των πρακτόρων. Το Best Run αποδεικνύει την αποτελεσματικότητα του RL Hunter, ενώ το Prey Escape δείχνει την ικανότητα του Prey να μαθαίνει διαφυγή.

Σύνοψη Αποτελεσμάτων

Παίγνιο	Σενάριο	Απόσταση Nash (P1/P2)	Cumulative Reward (P1/P2)	Παρατηρήσεις
Matching Pennies	FP vs FP	0.0007 / 0.0092	+60 / -60	Σύγκλιση NE
	FP vs RL	0.0000 / 0.6642	-374 / +374	RL εκμεταλλεύεται FP
	RL vs RL	0.6642 / 0.6642	-4 / +4	Δεν συγκλίνει
Rock-Paper-Scissors	FP vs FP	0.0032 / 0.0032	0 / 0	Τέλεια σύγκλιση
	FP vs RL	0.0152 / 0.7670	-213 / +213	RL εκμεταλλεύεται FP
	RL vs RL	0.7670 / 0.7670	+212 / -212	Κυκλική δυναμική
Grid Game	MinMax vs RL (Hunter 1°)	—	Hunter +6.998	Capture 6.5%
	MinMax vs RL (Prey 1°)	—	Hunter -87.869	Timeouts → αρνητικό
	RL vs RL (Hunter 1°)	—	Hunter +230.171	Capture 88.9%
	RL vs RL (Prey 1°)	—	Hunter +177.073	Capture 85.6%

FP vs FP:
Σύγκλιση στο Nash σε self-play — επιβεβαιώνει θεωρία Robinson.

FP vs RL:
«Κοντά στο Nash» ≠ «Κερδίζω» vs adaptive αντίπαλο.

Grid RL vs RL:
Capture 85–89% vs 6.5% MinMax — RL Hunter κυριαρχεί.

Συμπεράσματα

Fictitious Play

Συγκλίνει στο Nash σε self-play (MP, RPS).

Ευάλωτη σε RL: δεν είναι no-regret, regret γραμμικό. «Κοντά στο Nash» $\neq$ «κερδίζω» vs adaptive αντίπαλο.

Q-Learning

Εκμεταλλεύεται FP (MP: +374, RPS: +213). Σε RL vs RL matrix: δεν συγκλίνει σε Nash. Grid: 85–89% capture. Ισχυρό σε μικρά state spaces.

Minimax

Βέλτιστη παιξιά με τέλεια πληροφορία. Capture 6.5% – αξιοπρεπές αλλά RL Prey μαθαίνει διαφυγή.

Επιλογή Μεθόδου

Στόχος	Μέθοδος
Equilibrium computation	Fictitious Play
Robust / ασφαλής πολιτική	Minimax
Πρακτική βελτιστοποίηση	Reinforcement Learning

Βασικά Ευρήματα

1. FP & Q-Learning. Το FP στοχεύει στη σύγκλιση σε ισορροπία (equilibrium), ενώ το RL στη βελτιστοποίηση της πολιτικής.

2. Nash = ασφάλεια vs τέλειου αντιπάλου. Δεν εγγυάται μέγιστο κέρδος απέναντι σε έναν προσαρμοστικό αντίπαλο.

3. Exploitability εξαρτάται αποκλειστικά από το ϵ . Είναι το exploration rate που καθορίζει τα κενά της στρατηγικής και το πόσο εκμεταλλεύσιμη είναι.

4. Στο Grid, το capture rate δεν αρκεί. Η πλήρης εικόνα απαιτεί την κατανομή των εκβάσεων, η οποία αλλάζει δραματικά ανάλογα με τη σειρά κίνησης.

Ευχαριστούμε πολύ