

Fictitious Play και Reinforcement Learning

Υπολογισμός ισορροπιών σε μηδενικού αθροίσματος και στοχαστικά παίγνια

Πλέσσας Γιώργος, Τσαγκέτας Ορέστης — Φεβρουάριος 2026

Θεωρητικό πλαίσιο

Zero-sum παίγνια

$U_1 + U_2 = 0$. Πίνακας αποδόσεων M : $M[i,j]$ payoff του Row όταν παίζουν (i,j) . Μικτές στρατηγικές $x \in \Delta_m, y \in \Delta_n$. $u(x,y)=x^TMy$.

Ισορροπία Nash

(x^*,y^*) όπου $x^* \in \operatorname{argmax} x^TMy^*, y^* \in \operatorname{argmin} (x^*)^TMy$. Σε MP δεν υπάρχει pure NE, μοναδικό mixed NE: $(0.5,0.5)$. Σε RPS: $(1/3,1/3,1/3)$.

Θεώρημα Minimax

$$\max_x \min_y x^TMy = \min_y \max_x x^TMy$$

Η minimax στρατηγική ταυτίζεται με το Nash. Εφαρμόζεται σε sequential games με τέλεια πληροφορία.

Fictitious Play και Q-Learning

FP (model-based)

$$\hat{y}_i(a) = w_i(a) / \sum w_i(a')$$

belief = εμπειρική συχνότητα αντιπάλου. Σε κάθε γύρο: Best Response στο belief.
Ντετερμινιστική επιλογή.

Θεωρία Robinson: συγκλίνει στο mixed Nash σε zero-sum. Ευάλωτη σε προσαρμοστικούς αντιπάλους.

Q-Learning (model-free)

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a')]$$

ε-greedy επιλογή. Δεν μοντελοποιεί αντίπαλο. Προσαρμόζεται σε δυναμικούς αντιπάλους.

Σε non-stationary (RL vs RL) δεν συγκλίνει απαραίτητα σε Nash.

Μετρικές και παιγνία

Μετρικές αξιολόγησης

Απόσταση Nash (L2): $\|strategy - nash\|$. Exploitability: payoff αντιπάλου με best response. Cumulative reward. External regret: $best_fixed - actual$.

Παιγνία

Matching Pennies 2×2, NE (0.5,0.5) | Rock-Paper-Scissors 3×3, NE (1/3,1/3,1/3) | Grid Hunter-Prey 3×3 turn-based, capture/timeout.

Παράμετροι

Matrix: 10000 iterations, $\alpha=0.1$, $\epsilon=0.1$, seed=42. Grid: 200000 turns, Minimax depth=4, $\gamma=0.99$.

Σύνοψη αποτελεσμάτων

Παίγνιο	Σενάριο	Απόσταση Nash (P1/P2)	Cumulative Reward (P1/P2)	Παρατηρήσεις
Matching Pennies	FP vs FP	0.0007 / 0.0092	60 / -60	Σύγκλιση στο NE
	FP vs RL	0.0000 / 0.6642	-374 / +374	RL εκμεταλλεύεται FP
	RL vs RL	0.6642 / 0.6642	-4 / +4	Δεν συγκλίνει
Rock-Paper-Scissors	FP vs FP	0.0032 / 0.0032	0 / 0	Τέλεια σύγκλιση
	FP vs RL	0.0152 / 0.7670	-213 / +213	RL εκμεταλλεύεται FP
	RL vs RL	0.7670 / 0.7670	+212 / -212	Κυκλική δυναμική
Grid Game	MinMax vs RL (Hunter 1°)	—	Hunter +6998.5	Capture 6.5%
	MinMax vs RL (Prey 1°)	—	Hunter -87868.8	Capture 6.6%, timeouts
	RL vs RL (Hunter 1°)	—	Hunter +230170.7	Capture 88.9%
	RL vs RL (Prey 1°)	—	Hunter +177072.6	Capture 85.6%

Ροή πειραμάτων και αρχιτεκτονική

Matrix games (MP, RPS)

1. agent1.act(game), agent2.act(game) ταυτόχρονα
2. payoff1=get_payoff(a1,a2), payoff2=-payoff1
3. agent1.update(a1,payoff1,a2), agent2.update(a2,payoff2,a1)
4. get_strategy(), distance_to_nash, exploitability, αποθήκευση

Turn-based (Grid)

1. current_player → act(game,state)
2. game.step(action) → (reward,done,next_player)
3. update(...,next_state,done)
4. done → reset, καταγραφή rewards

Αρχιτεκτονική

games/: BaseGame, MatchingPennies, RPS, GridGame. get_payoff, best_response, get_nash.



agents/: FP, QLearning, StochasticQLearning, Minimax. act, update, get_strategy, reset.

experiments/: fp_vs_fp, fp_vs_rl, rl_vs_rl. ExperimentRunner.

analysis/: metrics.py, visualizer. distance_to_nash, exploitability, external_regret.

Matching Pennies — FP vs FP





10.000 iterations. FP1 distance: 0.0007 | FP2: 0.0092. Cumulative: +60 / -60. Average ± 0.0060 . Belief συγκλίνει στο 0.5. Και οι δύο κοντά στο NE (0.5,0.5).



Matching Pennies — FP vs RL

Row=FP, Column=Q-learning ($\alpha=0.1, \epsilon=0.1$). FP distance: 0.0000 | RL: 0.6642. Cumulative: FP -374, RL +374. FP external regret: 388, RL: -374. RL εκμεταλλεύεται την determinist αντίδραση FP.

Μετρική	FP	RL
Distance Nash	0.0000	0.6642
Cumulative reward	-374	+374
External regret	388	-374






Matching Pennies — RL vs RL

RL1 & RL2 distance: 0.6642. Cumulative: -4 / +4. Non-stationary περιβάλλον, κανείς δεν συγκλίνει στο Nash.

	$\epsilon=0.05$	$\epsilon=0.10$	$\epsilon=0.20$
$\alpha=0.01$	1.9099	1.8217	1.6508
$\alpha=0.10$	1.9099	1.8217	1.6508
$\alpha=0.50$	1.9099	1.8217	1.6508




Exploitability heatmap (5k iterations). Εξαρτάται μόνο από ϵ , όχι α .



Rock-Paper-Scissors

Σενάριο	Distance P1/P2	Cumulative P1/P2	Παρατηρήσεις
FP vs FP	0.0032 / 0.0032	0 / 0	Τέλεια σύγκλιση (1/3,1/3,1/3)
FP vs RL	0.0152 / 0.7670	-213 / +213	RL εκμεταλλεύεται, FP regret 234
RL vs RL	0.7670 / 0.7670	+212 / -212	Κυκλική δυναμική, ισχυρή ασυμμετρία




Exploitability sweep (α, ϵ): 0.88–0.97. Εξαρτάται μόνο από ϵ .



Grid Hunter-Prey — MinMax vs RL

Πρώτος	Episodes	Captures	Capture rate	Hunter total	Hunter mean
Hunter	10.264	670	6.5%	+6.998,5	+0.0698
Prey	10.282	682	6.6%	-87.868,8	-0.8787

Hunter first: MinMax κυριαρχεί. Prey first: πολλά timeouts → αρνητικό Hunter reward (-87k). RL Prey μαθαίνει να διαφεύγει. Capture rate παρόμοιο αλλά διαφορετική κατανομή τερματικών (timeouts).



Grid Hunter-Prey — RL vs RL

Πρώτος	Episodes	Captures	Capture rate	Hunter total	Hunter mean
Hunter	18.872	16.775	88.9%	+230.170,7	+2.1236
Prey	17.656	15.119	85.6%	+177.072,6	+1.7707

85–89% capture vs 6.5% στο MinMax vs RL. RL Hunter κυριαρχεί. Όταν και οι δύο μαθαίνουν, ο Hunter μαθαίνει να κυνηγά πιο αποτελεσματικά από ότι το Prey μαθαίνει να διαφεύγει. Σε μικρό state space το tabular Q-learning παράγει ισχυρές πολιτικές. Στο MinMax vs RL το Prey αντιμετωπίζει «τέλειο» Hunter και ασκείται στη διαφυγή· στο RL vs RL η συμπρωτεύουσα εξέλιξη οδηγεί σε κυριαρχία Hunter.

Συμπεράσματα

FP

Συγκλίνει στο Nash σε self-play (MP, RPS). Ευάλωτη σε RL: δεν είναι no-regret, regret γραμμικό. «Κοντά στο Nash» $\neq$ «κερδίζω» όταν ο αντίπαλος αλλάζει.

Q-Learning

Εκμεταλλεύεται FP (MP: +374, RPS: +213). Σε RL vs RL matrix: δεν συγκλίνει σε Nash, non-stationary. Στο Grid: RL Hunter 85–89% capture vs 6.5% MinMax vs RL.

Επιλογή μεθόδου

Equilibrium computation (FP) | Robust/minimax | Πρακτική βελτιστοποίηση (RL). FP και Q-learning δεν είναι ανταγωνιστές — διαφορετικός στόχος. Nash = ασφάλεια απέναντι σε βέλτιστο αντίπαλο, όχι εγγύηση reward vs μαθησιακό.

Exploitability και No-Regret

Exploitability (RL vs RL)

MP: 1.65–1.91. RPS: 0.88–0.97. Εξαρτάται μόνο από ϵ : μεγαλύτερο $\epsilon \rightarrow$ πιο ομοιόμορφη στρατηγική $\rightarrow$ μικρότερη exploitability. Learning rate α δεν επηρεάζει.

RPS	$\epsilon=0.05$	$\epsilon=0.10$	$\epsilon=0.20$
$\alpha=0.01$	0.9697	0.9393	0.8787
$\alpha=0.10$	0.9697	0.9393	0.8787
$\alpha=0.50$	0.9697	0.9393	0.8787

No-Regret

No-regret αλγόριθμοι: sublinear external regret $O(\sqrt{T})$. FP δεν είναι no-regret απέναντι σε RL: regret γραμμικό (388 MP, 234 RPS). RL vs FP: αρνητικό regret (RL κερδίζει περισσότερο από best fixed).

Σύστημα ανταμοιβών

Matrix: +1/-1 ή 0, $R_1+R_2=0$. Grid: capture +10/-10, timeout -10/+10, distance shaping. $\gamma=0.99$.

Ευχαριστώ

Fictitious Play και Reinforcement Learning — Υπολογισμός ισορροπιών σε μηδενικού αθροίσματος και στοχαστικά παίγνια

Πλέσσιας Γιώργος, Τσαγκέτας Ορέστης