



Λήψη σύνθετων αποφάσεων

Ακολουθιακά προβλήματα αποφάσεων

- Στοχαστικό περιβάλλον




- Πιθανότητα επίτευξης του στόχου από την ακολουθία
[Επάνω, Επάνω, Δεξιά, Δεξιά, Δεξιά]
– $0,8^5 + 0,1^4 \times 0,8, = 0,32776$

Διαδικασίες απόφασης Markov (Markov Decision Processes, MDPs)

- Ορισμός:
 - Αρχική κατάσταση: S_0
 - Μοντέλο Μετάβασης: $T(s, a, s')$
 - Συνάρτηση Ανταμοιβής: $R(s)$
- Πολιτικές, π
 - Ιστορικό του περιβάλλοντος
 - Ποιότητα της πολιτικής: Αναμενόμενη χρησιμότητα των δυνατών ιστορικών του περιβάλλοντος, που δημιουργούνται από την πολιτική


Βέλτιστες πολιτικές

- Βέλτιστη πολιτική, π^*



(α)

Εξισορρόπηση κινδύνου / ωφέλειας



(β)

Βέλτιστη συμπεριφορά

- Πεπερασμένος ορίζοντας
 - Μη στάσιμες πολιτικές
- Άπειρος ορίζοντας
 - Στάσιμες πολιτικές
- Πολυκριτηριακή θεωρία χρησιμότητων: Κατάσταση s_t αποτελεί κριτήριο της κάθε ακολουθίας που συμμετέχει.
- Στάσιμες προτιμήσεις
 - Προσθετικές ανταμοιβές
 - $U_h([s_0, s_1, s_2 \dots]) = R(s_0) + R(s_1) + R(s_2) + \dots$
 - Προεξοφλημένες ανταμοιβές
 - $U_h([s_0, s_1, s_2 \dots]) = R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots$

Άπειροι ορίζοντες

- Προεξοφλημένες ανταμοιβές, φραγμένη $R(s)$
- Κατάλληλες πολιτικές
 - Εγγυώνται ότι θα καταλήξουν σε τερματική κατάσταση
 - Προϋπόθεση να υπάρχουν τερματικές καταστάσεις
- Μέση ανταμοιβή
- Αξία πολιτικής: Αναμενόμενη ανταμοιβή για όλες τις δυνατές ακολουθίες καταστάσεων

$$\text{– π.χ. } \pi^* = \arg \max_{\pi} E \left[\sum_{t=0}^{\infty} \gamma^t R(s_t) \mid \pi \right]$$

Επανάληψη αξιών

Value iteration

Χρησιμότητες καταστάσεων

- Η χρησιμότητα μιας κατάστασης ισούται με την αναμενόμενη χρησιμότητα των ακολουθιών καταστάσεων που ξεκινούν από αυτήν.
 - Για μια συγκεκριμένη πολιτική π .

$$U^{\pi}(s) = E \left[\sum_{t=0}^{\infty} \gamma^t R(s_t) \mid \pi, s_0 = s \right]$$

- Η πραγματική χρησιμότητα (ανεξαρτήτως πολιτικής) ορίζεται ως:
 - $U(s) = U^{\pi^*}(s)$

Εξίσωση Bellman

- Ορισμός βέλτιστης πολιτικής με βάση τις χρησιμότητες:

$$\pi^*(s) = \arg \max_a \sum_{s'} T(s, a, s') U(s')$$

(προεξέταση βήματος με βάση την U_i)

- Εξίσωση Bellman:

$$U(s) = R(s) + \gamma \max_a \sum_{s'} T(s, a, s') U(s')$$

Παράδειγμα

- Για $\gamma=1$ και $R(s)=-0,04$ για τις μη-τερματικές καταστάσεις.
- Επαλήθευση, για $s=(1,1)$:

$$- U(1, 1) = -0,04 + \gamma \max\{0,8U(1, 2) + 0,1U(2, 1) + 0,1U(1, 1),$$

$$0,9U(1, 1) + 0,1U(1, 2)$$

$$0,9U(1, 1) + 0,1U(2, 1)$$

$$0,8U(2, 1) + 0,1U(1, 2) + 0,1U(1, 1) \}$$

Καλύτερη ενέργεια
η μετακίνηση στο (1,2)




3	0.812	0.868	0.918	+ 1
2	0.762		0.660	- 1
1	0.705	0.655	0.611	0.388
	1	2	3	4

Ο αλγόριθμος επανάληψης αξιών (Value-iteration algorithm)

- **function** Value-Iteration (mdp, ϵ) **returns** μια συνάρτηση χρησιμότητας
 - **inputs:** mdp , MDP με καταστάσεις S , μοντέλο μετάβασης T , συνάρτηση ανταμοιβής R , προεξόφληση γ
 - ϵ , το μέγιστο σφάλμα που επιτρέπεται στη χρησιμότητα κάθε κατάστασης
 - **local variables:** U, U' , διανύσματα χρησιμότητων για καταστάσεις στο S , αρχικά μηδενικά
 - δ , η μέγιστη μεταβολή στη χρησιμότητα οποιασδήποτε κατάστασης σε μια επανάληψη
 - **repeat**
 - $U \leftarrow U'$; $\delta \leftarrow 0$
 - **for each** κατάσταση s **in** S **do**
$$U'[s] \leftarrow R[s] + \gamma \max_a \sum_{s'} T(s, a, s') U[s']$$
 - **if** $|U'[s] - U[s]| > \delta$ **then** $\delta \leftarrow |U'[s] - U[s]|$
 - **until** $\delta < \epsilon(1 - \gamma) / \gamma$
 - **return** U

Παράδειγμα

- Εφαρμογή της επανάληψης αξιών για επιλεγμένες καταστάσεις του προβλήματος ($\gamma=1$, $R(s)=-0,04$).



Σύγκλιση της επανάληψης αξιών (1/2)

- Η επανάληψη αξιών συγκλίνει σε ένα και μοναδικό σύνολο λύσεων.
- **Συστολή** (contraction) είναι μια συνάρτηση ενός ορίσματος, η οποία, όταν εφαρμόζεται σε δύο διαφορετικές εισόδους, δίνει δύο τιμές εξόδου που είναι "πιο κοντινές μεταξύ τους" κατά τουλάχιστον μια σταθερή ποσότητα, σε σύγκριση με τα αρχικά ορίσματα.
 - π.χ. $f(x)=x/2$
- Ιδιότητες συστολών:
 - Έχει ένα μόνο σταθερό σημείο.
 - Η τιμή εξόδου προσεγγίζει πάντα το σταθερό σημείο.

Σύγκλιση της επανάληψης αξιών (2/2)

- Έστω U_i το διάνυσμα των χρησιμοτήτων για όλες τις καταστάσεις στην *ίσοστή* επανάληψη του υπολογισμού.
- Έστω B ο τελεστής Bellman, τότε:

$$U_{i+1} \leftarrow BU_i$$

- Νόρμα $\max$, για μέτρηση αποστάσεων διανυσμάτων:

$$\|U\| = \max_s |U(s)|$$

- Αποδεικνύεται ότι:

$$\|BU_i - BU'_i\| \leq \gamma \|U_i - U'_i\|$$

Σφάλμα της επανάληψης αξιών (1/2)

- Αντικαθιστώντας στην εξίσωση:

$$\|BU_i - BU'_i\| \leq \gamma \|U_i - U'_i\|$$

- το U'_i με τις πραγματικές χρησιμότητες U , για τις οποίες ισχύει $BU=U$, έχουμε:


$$\|BU_i - U\| \leq \gamma \|U_i - U\|$$

- Δηλαδή, το σφάλμα μειώνεται κατά τον παράγοντα γ .
- Το μέγιστο αρχικό σφάλμα είναι $2R_{\max}/(1 - \gamma)$.
- Για να πέσει το σφάλμα κάτω από ε απαιτούνται:

$$N = \lceil \log(2R_{\max}/\varepsilon(1 - \gamma)) / \log(1/\gamma) \rceil$$

επαναλήψεις.

Σφάλμα της επανάληψης αξιών (2/2)



- Οι επαναλήψεις αυξάνουν πολύ γρήγορα καθώς $\gamma \rightarrow 1$.


Τερματισμός της επανάληψης αξιών

- Θέλουμε ένα κριτήριο τερματισμού το οποίο να μην απαιτεί γνώση του τελικού διανύσματος χρησιμότητων U .
- Αποδεικνύεται ότι:
 - εάν $\|U_{i+1} - U_i\| < \varepsilon(1 - \gamma)/\gamma$ τότε $\|U_{i+1} - U\| < \varepsilon$

Απώλεια πολιτικής (1/2)

- Έστω U_i το διάνυσμα χρησιμοτήτων που πήραμε μετά τον τερματισμό του αλγορίθμου.
 - Σφάλμα πολιτικής: $\|U_i - U\|$
- Ορίζουμε:
 - $U^{\pi_i}(s)$: Η χρησιμότητα που λαμβάνουμε από την εκτέλεση της πολιτικής π_i στην κατάσταση s .
 - Απώλεια πολιτικής: $\max_s \|U^{\pi_i}(s) - U(s)\|$
- Στην πράξη συμβαίνει συχνά να γίνεται η πολιτική π_i βέλτιστη πολύ πριν από τη σύγκλιση του U_i .

Απώλεια πολιτικής (2/2)



Επανάληψη πολιτικών

Policy iteration

Ο αλγόριθμος επανάληψης πολιτικών

- **function** Policy-Iteration(mdp) **returns** μια πολιτική
 - **inputs:** mdp , μια MDP με καταστάσεις S , και μοντέλο μετάβασης T
 - **local variables:** U , U' , διανύσματα χρησιμότητας για καταστάσεις στο S , αρχικά μηδέν
 - π , ένα διάνυσμα πολιτικής που δεικτοδοτείται από τις καταστάσεις, αρχικά τυχαίο
 - **repeat**
 - $U \leftarrow \text{Policy-Evaluation}(\pi, U, mdp)$
 - $\text{αμετάβλητο?} \leftarrow \text{αληθές}$
 - **for each** κατάσταση s **in** S **do**
 - **if** $\max_{\alpha} \sum_{s'} T(s, \alpha, s') U[s'] > \sum_{s'} T(s, \pi[s], s') U[s']$ **then**
 - » $\pi[s] \leftarrow \arg\max_{\alpha} \sum_{s'} T(s, \alpha, s') U[s']$
 - » $\text{αμετάβλητο?} \leftarrow \text{ψευδές}$
 - **until** αμετάβλητο?
 - **return** π

Αξιολόγηση πολιτικών

- Με δεδομένο το διάνυσμα πολιτικών $\pi(s)$, η συνάρτηση Policy-Evaluation(π, U, mdp) υπολογίζει εξ αρχής το διάνυσμα χρησιμότητων U , λύνοντας γραμμικό σύστημα εξισώσεων (όσες και οι καταστάσεις):

$$U_i(s) = R(s) + \gamma \sum_{s'} T(s, \pi_i(s), s') U_i(s')$$

- Παράδειγμα:
 - $U_i(1, 1) = -0,04 + 0,8U_i(1, 2) + 0,1U_i(1, 1) + 0,1U_i(2, 1),$
 - $U_i(1, 2) = -0,04 + 0,8U_i(1, 3) + 0,2U_i(1, 2),$
 - ...
- Πολυπλοκότητα: $O(n^3)$
- Τροποποιημένη επανάληψη πολιτικών:
 - $U_{i+1}(s) \leftarrow R(s) + \gamma \sum_{s'} T(s, \pi_i(s), s') U_i(s') \quad (k \text{ επαναλήψεις})$